MACHINE LEARNING CANVAS

Designed for: MiBici, AMG Designed by: Equipo __ Date: 17/10/2026 Iteration: 1

PREDICTION TASK

What is the type of task?
Which entity are predictions made on?
What are the possible outcomes to predict?
When are outcomes observed?

Datos: ene 2022 a sep 2026 (post COVID). Unidad base: estación × hora.
P1 Regresión: viajes iniciados por estación (y zona H3) en cada hora del día siguiente. Horizonte 24 h. Lo observado es min(demanda, bicis disponibles): demanda censurada.
P2 Clasificación multiclase: estación × hora del día siguiente: {normal, riesgo de vaciado, riesgo de saturación}. Etiqueta proxy (no hay inventario): flujo neto horario vs. capacidad (≤ −50% vaciado, ≥ +50% saturación) más huellas de censura: hora pico sin salidas o salidas solo tras una llegada.
P3 Clustering: estaciones por perfil de uso. Sin objetivo; se valida con silueta, estabilidad bootstrap y lectura en el mapa.

DECISIONS

How are predictions turned into actionable recommendations or decisions for the end-user? (Mention parameters of the process / application for this.)

P1: el operador asigna bicicletas operativas y personal por zona para el día siguiente y programa mantenimiento en las horas de menor demanda pronosticada.
P2: lista de estaciones ordenada por probabilidad de riesgo y hora. Se programa visita de camión cuando p ≥ 1/(1+c), con c = costo FN / costo FP, limitada al top-K de visitas que cabe en cada turno.
P3: mapa de clusters para decidir dónde ampliar estaciones o anclajes y qué tipo de estación replicar.
Aprendizaje: se deja sin acción un 5% aleatorio de alertas de P2 para medir el efecto real del rebalanceo.

VALUE PROPOSITION

Who is the end beneficiary, and what specific pain points are addressed? How will the ML solution integrate with their workflow, and through which user interfaces?

Beneficiarios: usuarios de MiBici (encontrar bicicleta y anclaje), operador del sistema, equipo de rebalanceo y planeación urbana del AMG.
Dolores: estaciones vacías en zonas residenciales y llenas en zonas de oficinas por la mañana; rebalanceo reactivo; expansión sin evidencia de patrones de uso.
Integración: tablero nocturno con pronóstico y riesgos por estación y hora, más un CSV para planear rutas antes del primer turno; mapa interactivo de clusters.
Por qué desde 2022: la pandemia cambió horarios, trabajo en casa y motivos de viaje; los datos previos sesgarían los patrones hacia un régimen que ya no existe.

DATA COLLECTION

How is the initial set of entities and outcomes sourced (e.g., database extracts, API pulls, manual labeling)? What strategies are in place to update data continuously while controlling cost and maintaining freshness?

Pipeline reproducible: descarga de datos_abiertos_AAAA_MM.csv (2022-01 a 2026-09) y nomenclatura_2026_09.csv; detección de codificación (UTF-8 / Latin-1); mapeo de nombres de columna por año en un YAML; tipado y validación de esquema (pandera); guardado en Parquet por año y mes; manifiesto con hash SHA-256 versionado en Git.
Limpieza: viajes < 1 min con mismo origen y destino, duraciones > 3 h y estaciones inexistentes en la nomenclatura.
Actualización: job mensual al publicarse el nuevo CSV; la nomenclatura se versiona para registrar altas y bajas de estaciones. Las etiquetas de P2 se derivan de los propios viajes.

DATA SOURCES

Where can we get data on entities and observed outcomes? (Mention internal and external database tables or API methods.)

MiBici datos abiertos: viajes mensuales (id de viaje, usuario: id, género y año de nacimiento, fecha y hora de inicio y fin, estación de origen y destino).
Nomenclatura: id, nombre, latitud, longitud y capacidad de cada estación.
Externas: días festivos y calendario escolar SEP; clima histórico por hora (Open-Meteo); calendario de eventos masivos (p. ej. partidos del Mundial 2026 en Guadalajara).
Opcional: feed de disponibilidad en tiempo real (GBFS) si MiBici lo publica, para validar la etiqueta proxy de P2.

IMPACT SIMULATION

What are the cost/gain values for (in)correct decisions?
Which data is used to simulate pre-deployment impact?
What are the criteria for deployment?
Are there fairness constraints?

Costos P2: FN = viajes perdidos (salidas promedio de esa estación y hora × horas vacía); FP = visita innecesaria. c se estima con los datos.
Simulación: backtest temporal: train 2022-01 a 2025-06, validación 2025-07 a 2025-12, prueba 2026-01 a 2026-09.
Criterios: P1 cierra ≥ 50% de la brecha entre baseline y el piso Poisson de WAPE, con mejora significativa (Diebold-Mariano); P2 costo esperado menor que la regla Q3 (IC bootstrap) y alertas ≤ visitas por turno; P3 silueta > 0.25 y Jaccard bootstrap ≥ 0.75 por cluster.
Equidad: métricas por zona; la periferia no debe quedar fuera del rebalanceo.

MAKING PREDICTIONS

Are predictions made in batch or in real time?
How frequently?
How much time is available for this (including featurization and decisions)?
Which computational resources are used?

Batch. P1 y P2: diario a las 00:00 para las 24 horas del día siguiente (n estaciones × 24 filas). Con datos en tiempo real, P2 sería horario (horizonte 1 a 3 h).
P3: se recalcula cada trimestre o al dar de alta estaciones.
Tiempo: menos de 30 min incluyendo features (la ventana nocturna es amplia).
Recursos: CPU, contenedor Docker y modelos servidos desde el registro de MLflow.

BUILDING MODELS

How many models are needed in production?
When should they be updated?
How much time is available for this (including featurization and analysis)?
Which computation resources are used?

En producción: 3 modelos (P1, P2, P3) más sus baselines.
P1: baseline estacional; regresión Poisson; LightGBM global (Poisson / Tweedie). MAE, RMSE, WAPE.
P2: baseline regla Q3 de salidas propias; regresión logística; LightGBM con pesos de clase. Costo esperado, recall, precisión, PR-AUC.
P3: K-Means sobre PCA de perfiles; vs. Ward y GMM; k por silueta y Davies-Bouldin.
Actualización: mensual, ventana expansiva desde 2022, o antes si hay drift. < 2 h en CPU. MLflow, Git y manifiesto de datos.

FEATURES

What representations are used for entities at prediction time?
What aggregations or transformations are applied to raw data sources?

Calendario: hora, día de la semana, mes, festivo, vacaciones, quincena.
Rezagos: misma hora hace 24 h y 168 h; medias móviles 7 y 28 días (solo información disponible a las 00:00).
Estación: capacidad, lat / lon, zona H3, distancia al centro, vecinas en 500 m, cluster P3.
Flujo (P2): flujo neto histórico / capacidad; frecuencia histórica de huecos sin salidas en hora pico.
Contexto: temperatura, lluvia, eventos masivos.
P3 (por estación, 2022+): perfil horario de salidas y llegadas (hábil y fin de semana), razón llegadas / salidas, duración mediana, % circulares.

MONITORING

Which metrics and KPIs are used to track the ML solution's impact once deployed, both for end-users and for the business? How often should they be reviewed?

Modelo (semanal): WAPE por zona (P1), recall y precisión de riesgo (P2) contra lo observado; drift de datos (PSI de volumen y perfil horario); altas y bajas de estaciones; Jaccard de clusters cada trimestre. Reentrenar si se degradan más de 15%.

Negocio (mensual): % de horas-estación vacías o llenas, viajes perdidos estimados, km de rebalanceo por bicicleta reubicada, viajes por bicicleta al día.

Version 1.2. Created by Louis Dorard, Ph.D. Licensed under a Creative Commons Attribution-ShareAlike 4.0 International License.
Please keep this mention and the link to ownml.co when sharing.

OWNML.CO