

Instituto Tecnológico y de Estudios Superiores de Monterrey

Operaciones de aprendizaje automático

Construye | Proyecto MiBici: propuesta y base reproducible | Colaborativo

José Alfredo Gutiérrez Guerra · A01203331
Antonio Abraham Díaz Arvizu · A01797914
Damián López Virgen · A01840290
José Antonio Padilla Pereira · A01840574

18 de Octubre de 2026

Repositorio:
https://github.com/agtz92/TC5061-Proyecto-Equipo24

MACHINE LEARNING CANVAS

Designed for: MiBici, AMG | Designed by: Equipo 24 | Date: 17/10/2026 | Iteration: 1

PREDICTION TASK

What is the type of task?
Which entity are predictions made on?
What are the possible outcomes to predict?
When are outcomes observed?

Datos: ene 2022 a sep 2026 (post COVID). Unidad base: estación × hora.
P1 Regresión: viajes iniciados por estación (y zona H3) en cada hora del día siguiente. Horizonte 24 h. Lo observado es min(demanda, bicis disponibles): demanda censurada.
P2 Clasificación multiclase: estación × hora del día siguiente: {normal, riesgo de vaciado, riesgo de saturación}. Etiqueta proxy (no hay inventario): flujo neto horario vs. capacidad (≤ −50% vaciado, ≥ +50% saturación) más huellas de censura: hora pico sin salidas o salidas solo tras una llegada.
P3 Clustering: estaciones por perfil de uso. Sin objetivo; se valida con silueta, estabilidad bootstrap y lectura en el mapa.

DECISIONS

How are predictions turned into actionable recommendations or decisions for the end-user? (Mention parameters of the process / application for this.)

P1: el operador asigna bicicletas operativas y personal por zona para el día siguiente y programa mantenimiento en las horas de menor demanda pronosticada.
P2: lista de estaciones ordenada por probabilidad de riesgo y hora. Se programa visita de camión cuando p ≥ 1/(1+c), con c = costo FN / costo FP, limitada al top-K de visitas que cabe en cada turno.
P3: mapa de clusters para decidir dónde ampliar estaciones o anclajes y qué tipo de estación replicar.
Aprendizaje: se deja sin acción un 5% aleatorio de alertas de P2 para medir el efecto real del rebalanceo.

VALUE PROPOSITION

Who is the end beneficiary, and what specific pain points are addressed?
How will the ML solution integrate with their workflow, and through which user interfaces?

Beneficiarios: usuarios de MiBici (encontrar bicicleta y anclaje), operador del sistema, equipo de rebalanceo y planeación urbana del AMG.
Dolores: estaciones vacías en zonas residenciales y llenas en zonas de oficinas por la mañana; rebalanceo reactivo; expansión sin evidencia de patrones de uso.
Integración: tablero nocturno con pronóstico y riesgos por estación y hora, más un CSV para planear rutas antes del primer turno; mapa interactivo de clusters.
Por qué desde 2022: la pandemia cambió horarios, trabajo en casa y motivos de viaje; los datos previos sesgarían los patrones hacia un régimen que ya no existe.

DATA COLLECTION

How is the initial set of entities and outcomes sourced (e.g., database extracts, API pulls, manual labeling)?
What strategies are in place to update data continuously while controlling cost and maintaining freshness?

Pipeline reproducible: descarga de datos_abiertos_AAAA_MM.csv (2022-01 a 2026-09) y nomenclatura_2026_09.csv; detección de codificación (UTF-8 / Latin-1); mapeo de nombres de columna por año en un YAML; tipado y validación de esquema (pandera); guardado en Parquet por año y mes; manifiesto con hash SHA-256 versionado en Git.
Limpieza: viajes < 1 min con mismo origen y destino, duraciones > 3 h y estaciones inexistentes en la nomenclatura.
Actualización: job mensual al publicarse el nuevo CSV; la nomenclatura se versiona para registrar altas y bajas de estaciones. Las etiquetas de P2 se derivan de los propios viajes.

DATA SOURCES

Where can we get data on entities and observed outcomes? (Mention internal and external database tables or API methods.)

MiBici datos abiertos: viajes mensuales (id de viaje, usuario: id, género y año de nacimiento, fecha y hora de inicio y fin, estación de origen y destino).
Nomenclatura: id, nombre, latitud, longitud y capacidad de cada estación.
Externas: días festivos y calendario escolar SEP; clima histórico por hora (Open-Meteo); calendario de eventos masivos (p. ej. partidos del Mundial 2026 en Guadalajara).
Opcional: feed de disponibilidad en tiempo real (GBFS) si MiBici lo publica, para validar la etiqueta proxy de P2.

IMPACT SIMULATION

What are the cost/gain values for (in)correct decisions?
Which data is used to simulate pre-deployment impact?
What are the criteria for deployment?
Are there fairness constraints?

Costos P2: FN = viajes perdidos (salidas promedio de esa estación y hora × horas vacía); FP = visita innecesaria. c se estima con los datos.
Simulación: backtest temporal: train 2022-01 a 2025-06, validación 2025-07 a 2025-12, prueba 2026-01 a 2026-09.
Criterios: P1 cierra ≥ 50% de la brecha entre baseline y el piso Poisson de WAPE, con mejora significativa (Diebold-Mariano); P2 costo esperado menor que la regla Q3 (IC bootstrap) y alertas ≤ visitas por turno; P3 silueta > 0.25 y Jaccard bootstrap ≥ 0.75 por cluster.
Equidad: métricas por zona; la periferia no debe quedar fuera del rebalanceo.

MAKING PREDICTIONS

Are predictions made in batch or in real time?
How frequently?
How much time is available for this (including featurization and decisions)?
Which computational resources are used?

Batch. P1 y P2: diario a las 00:00 para las 24 horas del día siguiente (n estaciones × 24 filas). Con datos en tiempo real, P2 sería horario (horizonte 1 a 3 h).
P3: se recalcula cada trimestre o al dar de alta estaciones.
Tiempo: menos de 30 min incluyendo features (la ventana nocturna es amplia).
Recursos: CPU, contenedor Docker y modelos servidos desde el registro de MLflow.

BUILDING MODELS

How many models are needed in production?
When should they be updated?
How much time is available for this (including featurization and analysis)?
Which computation resources are used?

En producción: 3 modelos (P1, P2, P3) más sus baselines.
P1: baseline estacional; regresión Poisson; LightGBM global (Poisson / Tweedie). MAE, RMSE, WAPE.
P2: baseline regla Q3 de salidas propias; regresión logística; LightGBM con pesos de clase. Costo esperado, recall, precisión, PR-AUC.
P3: K-Means sobre PCA de perfiles; vs. Ward y GMM; k por silueta y Davies-Bouldin.
Actualización: mensual, ventana expansiva desde 2022, o antes si hay drift. < 2 h en CPU. MLflow, Git y manifiesto de datos.

FEATURES

What representations are used for entities at prediction time?
What aggregations or transformations are applied to raw data sources?

Calendario: hora, día de la semana, mes, festivo, vacaciones, quincena.
Rezagos: misma hora hace 24 h y 168 h; medias móviles 7 y 28 días (solo información disponible a las 00:00).
Estación: capacidad, lat / lon, zona H3, distancia al centro, vecinas en 500 m, cluster P3.
Flujo (P2): flujo neto histórico / capacidad; frecuencia histórica de huecos sin salidas en hora pico.
Contexto: temperatura, lluvia, eventos masivos.
P3 (por estación, 2022+): perfil horario de salidas y llegadas (hábil y fin de semana), razón llegadas / salidas, duración mediana, % circulares.

MONITORING

Which metrics and KPIs are used to track the ML solution's impact once deployed, both for end-users and for the business?
How often should they be reviewed?

Modelo (semanal): WAPE por zona (P1), recall y precisión de riesgo (P2) contra lo observado; drift de datos (PSI de volumen y perfil horario); altas y bajas de estaciones; Jaccard de clusters cada trimestre. Reentrenar si se degradan más de 15%.

Negocio (mensual): % de horas-estación vacías o llenas, viajes perdidos estimados, km de rebalanceo por bicicleta reubicada, viajes por bicicleta al día.

Version 1.2. Created by Louis Dorard, Ph.D. Licensed under a Creative Commons Attribution-ShareAlike 4.0 International License.
Please keep this mention and the link to ownml.co when sharing.

OWNML.CO

PLANTEAMIENTO DE LAS PREGUNTAS DEL PROYECTO

Ventana de datos: enero 2022 a septiembre 2026. Se excluyen 2014 a 2021 porque la pandemia de COVID-19 modificó de forma persistente los horarios, el trabajo en casa y los motivos de viaje; el objetivo es modelar el comportamiento post pandemia, que es el que enfrenta hoy la operación. La partición es temporal (nunca aleatoria): entrenamiento hasta jun 2025, validación jul a dic 2025 y prueba ene a sep 2026.

Pregunta	1) Qué se predice o agrupa, granularidad y horizonte	2) Por qué es relevante para la operación de MiBici	3) Quién usa el resultado y qué decisión toma
P1 Demanda de viajes (regresión)	Número de viajes iniciados por estación en cada hora del día siguiente (horizonte 24 h), agregable a zona (hexágono H3) y a total diario. Regresión sobre conteos con objetivo Poisson o Tweedie; baseline: misma hora de la semana anterior. Limitación: lo observado es la demanda censurada por las bicicletas disponibles, no la demanda real.	La demanda varía mucho por hora, día y zona. Conocerla con un día de anticipación permite dimensionar flota y personal en lugar de reaccionar cuando ya hay estaciones sin servicio. Además alimenta P2 con las salidas esperadas.	Operador del sistema. Decide cuántas bicicletas operativas asignar a cada zona, en qué horas programar mantenimiento (las de menor demanda) y dónde conviene reforzar la capacidad.
P2 Riesgo de vaciado o saturación (clasificación)	Para cada estación y bloque de 1 h del día siguiente, la clase {normal, riesgo de vaciado, riesgo de saturación} con su probabilidad. Como los datos no traen inventario, la etiqueta combina el flujo neto horario (llegadas menos salidas) relativo a la capacidad (≤ −50% vaciado, ≥ +50% saturación, umbral calibrado con la distribución observada) con huellas de censura: horas de alta demanda histórica sin salidas, o salidas que solo ocurren justo después de una llegada. Baseline: alertar cuando las salidas de la hora superan el tercer cuartil propio de la estación.	Una estación sin bicicletas o sin anclajes es un viaje perdido y la falla más visible del servicio. Anticiparla convierte el rebalanceo de reactivo a planeado y reduce kilómetros y visitas innecesarias de camión.	Equipo de rebalanceo. Con la lista ordenada por riesgo y hora define rutas y turnos: qué estaciones visitar, en qué orden y si debe llevar o retirar bicicletas, dentro de su capacidad diaria de visitas.
P3 Tipologías de estaciones (clustering)	Grupos de estaciones según su perfil de uso promedio 2022 a 2026: curvas horarias de salidas y llegadas en día hábil y fin de semana, balance llegadas / salidas, duración típica y proporción de viajes circulares. Granularidad: estación. Sin horizonte (análisis descriptivo que se recalcula cada trimestre); los grupos se proyectan en el mapa con latitud y longitud.	Revela tipologías (residencial de salida matutina, laboral de llegada matutina, mixta, recreativa) y cómo se distribuyen en la ciudad. Explica los desbalances que atiende P2 y aporta una variable a P1 y P2.	Planeación urbana y expansión del sistema. Decide dónde abrir estaciones nuevas (zonas sin cobertura con perfil similar a grupos de alta demanda), qué capacidad asignarles y dónde priorizar infraestructura ciclista.

Nota: la etiqueta de P2 es un proxy derivado de los viajes. Si MiBici publica disponibilidad en tiempo real (GBFS), se usará para validarla y recalibrar el umbral.

CRITERIOS DE APROBACIÓN Y SU JUSTIFICACIÓN

Todos los criterios se evalúan en el periodo de prueba (ene a sep 2026) contra un baseline simple. Ningún umbral es un porcentaje fijo: cada uno se deriva de un límite estadístico, de los costos de operación o de referencias publicadas.

Pregunta	Criterio para desplegar	Justificación
P1 Regresión	Cerrar al menos 50% de la brecha entre el WAPE del baseline (misma hora de la semana anterior) y el WAPE mínimo posible, evaluado por nivel de demanda (estación-hora, zona-hora, estación-día). La mejora sobre el baseline debe ser significativa: prueba de Diebold-Mariano o intervalo bootstrap por bloques que excluya cero.	Un porcentaje fijo de mejora no es comparable entre granularidades. Aunque el modelo conociera la demanda media exacta, los conteos varían de forma aleatoria (Poisson), lo que impone un error mínimo irreducible. WAPE mínimo según la media de viajes por periodo: 1 viaje, 74%; 3 viajes, 45%; 10 viajes, 25%; 30 viajes, 15%; 100 viajes, 8%. Ejemplo: si en estación-hora (unos 3 viajes) el baseline logra 55% y el piso es 45%, solo hay 10 puntos de margen y bajar 10% ya es mucho; a nivel zona-día el margen es amplio y 10% sería poco. Medir la fracción de brecha cerrada hace comparables ambos casos. La prueba de significancia evita aprobar una mejora debida al azar del periodo de prueba.
P2 Clasificación	Costo esperado del modelo menor que el de la regla baseline (alertar cuando las salidas superan el tercer cuartil propio de la estación), con intervalo bootstrap que excluya cero. Umbral de decisión p* = 1/(1+c) sobre probabilidades calibradas. Número de alertas por turno menor o igual a las visitas que el equipo de rebalanceo puede realizar.	Recall y precisión fijos no reflejan lo que le importa a la operación. Con c = costo de un falso negativo / costo de un falso positivo y probabilidades calibradas, el umbral que minimiza el costo esperado es 1/(1+c) (teoría de decisión bayesiana). c se estima con los datos: un falso negativo cuesta los viajes perdidos (salidas promedio de esa estación y hora durante el tiempo que estaría vacía); un falso positivo cuesta una visita de camión innecesaria. La restricción de capacidad asegura que la lista sea ejecutable. Recall, precisión y PR-AUC se reportan como diagnóstico. La regla Q3 marca por construcción el 25% de las horas de cada estación y solo mira salidas, no el balance con llegadas; por eso es un baseline razonable, pero no una etiqueta de riesgo.
P3 Clustering	Silueta promedio > 0.25. Estabilidad: Jaccard bootstrap promedio ≥ 0.75 en cada cluster. Interpretabilidad: cada cluster debe describirse con un perfil horario y una ubicación coherentes en el mapa.	Kaufman y Rousseeuw (1990): silueta de 0.26 a 0.50 indica estructura débil, de 0.51 a 0.70 razonable y > 0.70 fuerte. Se exige al menos estructura débil porque los perfiles de uso varían de forma continua y no se esperan grupos totalmente separados. Hennig (2007): con remuestreo bootstrap, un Jaccard ≥ 0.75 indica un cluster estable, de 0.60 a 0.75 un patrón con alguna incertidumbre y < 0.50 un cluster que se disuelve. Un grupo inestable no sirve para planear la expansión del sistema.

Referencias: Kaufman, L. y Rousseeuw, P. J. (1990). Finding Groups in Data. Wiley. Hennig, C. (2007). Cluster-wise assessment of cluster stability. Computational Statistics and Data Analysis, 52(1), 258-271. Diebold, F. X. y Mariano, R. S. (1995). Comparing predictive accuracy. Journal of Business and Economic Statistics, 13(3), 253-263.

1. DEFINICIÓN DE LOS DATOS

1.1 Rango de fechas propuesto y justificación

Usaremos los viajes de **enero de 2022 a septiembre de 2026** (57 meses, el último mes publicado) y la nomenclatura de estaciones de septiembre de 2026. Se excluyen 2014 a 2021 por tres razones:

- **Cambio de régimen por la pandemia.** El COVID-19 modificó horarios, trabajo en casa y motivos de viaje. Mezclar 2020 y 2021 con la operación actual sesgaría los patrones horarios que necesitan P1, P2 y P3 hacia un comportamiento que ya no existe.
- **Suficiencia.** 57 meses incluyen cuatro ciclos anuales completos (vacaciones, lluvias, fin de año), suficientes para aprender estacionalidad anual y semanal y para reservar nueve meses de prueba.
- **Costo de cómputo acotado.** El rango cabe en una laptop una vez convertido a Parquet, lo que permite que cualquier integrante reproduzca el pipeline completo.

El rango queda declarado una sola vez en config.py (START = "2022-01", END = "2026-09") y se registra como parámetro en cada run de MLflow.

1.2 Fuente

Portal de datos abiertos de MiBici: https://www.mibici.net/es/datos-abiertos/

Nomenclatura de estaciones: nomenclatura_2026_09.csv

Viajes: un archivo por mes, datos_abiertos_AAAA_MM.csv. Cada archivo vive en una carpeta distinta del servidor (por ejemplo https://www.mibici.net/site/assets/files/14797/datos_abiertos_2022_01.csv), por lo que dataset.py no construye la URL a partir de la fecha: lee la página del portal y toma los enlaces que coinciden con el patrón. El enlace exacto de cada uno de los 57 archivos está en el Anexo A.

Fuentes externas (para features): días festivos oficiales y calendario escolar de la SEP; clima horario histórico de Guadalajara (Open-Meteo, API de archivo histórico).

1.3 Tamaño real obtenido

Cifras medidas al descargar y contar los 57 archivos el 17 de octubre de 2026 (detalle por mes en el Anexo A):

Medida	Valor	Observación
Meses	57	2022-01 a 2026-09, sin meses faltantes
Viajes (filas)	21,036,075	promedio de 369,054 por mes; mínimo 289,864 (2022-01), máximo 490,056 (2026-09)
Volumen en CSV	1,796 MB	se reduce de forma importante al guardarse en Parquet con compresión
Estaciones con al menos un viaje	473	de 300 activas en 2022-01 a 468 en 2026-09; la red creció en oct 2023 (300 a 359) y en jun a sep 2026 (371 a 468), así que unas 100 estaciones tienen menos de 4 meses de historia
Estaciones en la nomenclatura 2026-09	484	capacidad total 8,171 anclajes; mediana 15 por estación (rango 0 a 39); 356 en Guadalajara, 110 en Zapopan, 17 en Tlaquepaque y 1 sin prefijo
Codificación	36 archivos en Latin-1 y 21 en UTF-8	se detecta por archivo; no se puede asumir una sola
Esquema de columnas	8 columnas iguales en todos los meses; en 2 meses (2024-02 y 2024-05) el encabezado Año_de_nacimiento llega corrupto (*) y en 3 meses (2023-11, 2024-09 y 2024-10) las fechas vienen como dd/mm/aaaa h:mm sin segundos (†)	se normaliza con un mapeo explícito en config.py

1.4 Variables originales y construcción de las variables objetivo

Variable original	Uso	Tratamiento	Para qué sirve
Viaje_Id	Control	Llave para eliminar duplicados	Calidad de datos; no entra al modelo
Inicio_del_viaje	P1, P2, P3	Fecha y hora local; se trunca a la hora	Define la hora de la salida, el calendario y la duración
Fin_del_viaje	P2, P3	Fecha y hora local; se trunca a la hora	Define la hora de la llegada y la duración del viaje
Origen_Id	P1, P2, P3	Se valida contra la nomenclatura	Estación donde ocurre la salida
Destino_Id	P2, P3	Se valida contra la nomenclatura	Estación donde ocurre la llegada
id, latitude, longitude, dpcapacity (nomenclatura)	P1, P2, P3	Tabla de dimensión de estaciones	Ubicación para mapas y vecindad; capacidad para normalizar el flujo neto
Usuario_Id, Genero, Año_de_nacimiento	Ninguno	Se eliminan en la ingesta (ver 1.5)	No son necesarios para ninguna de las tres preguntas

P1 (regresión). y(s, h) = número de viajes con Origen_Id = s cuyo Inicio_del_viaje cae en la hora h. Se completa con ceros cada hora en que la estación estaba activa (entre su primer y su último viaje registrado) y no tuvo salidas, para no confundir "sin demanda" con "sin dato". Las agregaciones a zona (hexágono H3) y a día son sumas de y(s, h).

P2 (clasificación multiclase). Para cada estación s y hora h se calculan salidas d(s, h), llegadas a(s, h) y flujo neto n(s, h) = a(s, h) menos d(s, h). La clase es:

- **Riesgo de vaciado** si n(s, h) / capacidad(s) ≤ −0.5, o si hay huella de censura de salidas: el promedio histórico de salidas de esa estación, día de la semana y hora en las 8 semanas previas es ≥ 3 y en h no hubo ninguna salida.
- **Riesgo de saturación** si n(s, h) / capacidad(s) ≥ +0.5, o si hay huella de censura de llegadas (mismo criterio aplicado a las llegadas).
- **Normal** en cualquier otro caso. Los umbrales 0.5 y 3 se calibran con la distribución del periodo de entrenamiento y quedan en config.py.

P3 (clustering). No hay variable objetivo. Cada estación se representa con un vector de 96 valores: proporción de salidas y de llegadas en cada hora del día, por separado en días hábiles y en fin de semana (cada bloque de 24 suma 1), más la razón llegadas / salidas, la duración mediana de los viajes y el porcentaje de viajes circulares (origen igual a destino).

1.5 Condiciones de uso y tratamiento de datos personales

Lo que publica MiBici. La página de datos abiertos ofrece los archivos y un manual de uso, pero no declara una licencia de reutilización. El pie del sitio indica "Todos los derechos reservados Mi Bici © 2026". Los Términos y condiciones regulan el uso del servicio de bicicletas (suscripción, facturación), no la reutilización de los datos. El Aviso de privacidad lo emite la Agencia Metropolitana de Servicios de Infraestructura para la Movilidad (AMIM), cubre datos de personal, visitantes y trámites, y se fundamenta en la Ley de Protección de Datos Personales en Posesión de Sujetos Obligados del Estado de Jalisco y sus Municipios; no menciona el conjunto de viajes.

Interpretación y uso que daremos. Los datos se publican por un sujeto obligado como datos abiertos, por lo que los usaremos solo con fines académicos, citando la fuente, y sin redistribuir copias: el repositorio contiene el script de descarga, no los datos (data/ está en .gitignore).

Datos personales. Usuario_Id es un seudónimo, pero combinado con género, año de nacimiento y la secuencia de horas y estaciones de sus viajes permitiría reidentificar a una persona; en trazas de movilidad bastan unos pocos puntos espacio-temporales para hacer única a la mayoría de los individuos (de Montjoye et al., 2013). Por ello:

- dataset.py elimina Usuario_Id, Genero y Año_de_nacimiento al convertir a Parquet; ningún archivo intermedio los conserva.
- Todos los modelos trabajan sobre agregados por estación y hora; nunca a nivel de persona.
- En MLflow no se registran datos a nivel de viaje ni de usuario como parámetros, etiquetas o artefactos; solo métricas agregadas, gráficas y el modelo.
- Las figuras y tablas publicadas en reports/ muestran estaciones o zonas, nunca trayectorias individuales.

1.6 Estrategia de partición y prevención de fuga de información

Conjunto	Periodo	Uso
Entrenamiento	2022-01 a 2025-06 (42 meses)	Ajuste de modelos y de umbrales; validación cruzada temporal interna (TimeSeriesSplit con hueco de 1 día) para elegir hiperparámetros
Validación	2025-07 a 2025-12 (6 meses)	Selección del modelo final, calibración de probabilidades (P2) y elección de k (P3)
Prueba	2026-01 a 2026-09 (9 meses)	Una sola evaluación final contra los criterios de aprobación; se reporta también sin los días de partidos del Mundial 2026 (junio)

La partición es estrictamente cronológica; nunca aleatoria, porque las horas contiguas están correlacionadas y una división aleatoria filtraría el futuro al entrenamiento. Además:

- **Features con corte en la predicción.** Se predice a las 00:00 para el día siguiente, así que cada feature usa solo información hasta las 23:59 del día anterior: rezagos de 24 h y 168 h, y promedios móviles desplazados un día.
- **Umbrales y estadísticas solo con el pasado.** El tercer cuartil del baseline de P2, los promedios esperados de la huella de censura, los escaladores y codificadores se calculan con datos anteriores a cada punto de corte (o solo con entrenamiento).
- **Estaciones activas.** Una estación entra al conjunto solo a partir de su primer viaje; no se generan ceros para estaciones que aún no existían.
- **Capacidad.** La nomenclatura es una foto de 2026-09; si una estación cambió de capacidad, el dato es posterior al periodo de entrenamiento. Se declara como limitación y se mide su efecto comparando P2 con y sin la normalización por capacidad.
- **Clustering.** Los clusters se ajustan con el periodo de entrenamiento y su estabilidad se comprueba asignando las estaciones con los perfiles de validación y prueba.

2. DISEÑO DEL PIPELINE DE ML

Las tres preguntas comparten la ingesta y la limpieza (dataset.py) y se separan a partir de la agregación (features.py). Cada etapa es una función del módulo del proyecto, parametrizada desde config.py, y el entrenamiento se lanza con mlflow run.

Etapa	P1 Demanda (regresión)	P2 Riesgo (clasificación)	P3 Tipologías (clustering)
Ingesta y limpieza (común)	Descarga de los 57 CSV y la nomenclatura; detección de codificación; mapeo de columnas; tipado de fechas en hora local de Guadalajara. Se eliminan duplicados de Viaje_Id, viajes con duración ≤ 0 o > 3 h, viajes < 1 min con mismo origen y destino (anclajes fallidos) y estaciones que no están en la nomenclatura. Se descartan las columnas personales. Salida: Parquet por año y mes + manifiesto con hash.	Igual que P1.	Igual que P1.
Agregación	Conteo de salidas por estación y hora con relleno de ceros; sumas por zona H3 y por día.	Salidas, llegadas y flujo neto por estación y hora; flujo neto / capacidad; huellas de censura; etiqueta de 3 clases.	Perfil promedio por estación (96 valores) con los viajes del periodo de entrenamiento; razón llegadas / salidas, duración mediana, % circulares.
Feature engineering	Calendario, rezagos 24 h y 168 h, promedios móviles 7 y 28 días, atributos de la estación, clima, eventos, cluster de P3.	Las de P1 más flujo neto histórico por hora / capacidad, frecuencia histórica de huellas de censura y pronóstico de salidas de P1.	Estandarización de los vectores; reducción con PCA conservando ≥ 90% de la varianza.
Entrenamiento	Baseline estacional; regresión de Poisson; LightGBM global con objetivo Poisson. Hiperparámetros por validación cruzada temporal.	Baseline regla Q3; regresión logística multinomial; LightGBM con pesos de clase; calibración de probabilidades.	Baseline por municipio; K-Means, jerárquico (Ward) y GMM para k = 3 a 10.
Evaluación	Métricas en validación y prueba por nivel de demanda; comparación contra el piso Poisson y prueba de significancia.	Costo esperado con umbral 1/(1+c); métricas por clase; alertas por turno contra capacidad del equipo.	Silueta, Davies-Bouldin, estabilidad bootstrap; mapa y perfiles de cada cluster.

Variables que se construirán y por qué son pertinentes

Variable	Definición	Preguntas	Pertinencia
hora, dia_semana, mes, es_festivo, vacaciones_sep, quincena	Derivadas de la hora de predicción y de los calendarios externos	P1, P2	La demanda de bicicleta compartida sigue ciclos de traslado laboral y escolar; los festivos y vacaciones rompen ese ciclo.
lag_24h, lag_168h	Viajes (o flujo neto) de la misma estación a la misma hora hace 1 día y hace 1 semana	P1, P2	Capturan la inercia y la estacionalidad semanal; el baseline estacional es lag_168h, así que el modelo debe mejorar sobre él.
media_movil_7d, media_movil_28d	Promedio por estación y hora en las últimas 1 y 4 semanas, desplazado un día	P1, P2	Separan el nivel reciente de la estación del ruido de una sola hora y siguen tendencias (estaciones nuevas, obras).
capacidad, lat, lon, zona_h3, dist_centro, vecinas_500m	Atributos de la nomenclatura	P1, P2, P3	Permiten un modelo global que comparte información entre estaciones; las estaciones con muchas vecinas reparten la demanda.
flujo_neto_rel	Flujo neto histórico de la estación a esa hora dividido entre su capacidad	P2	Es la variable que define el riesgo; su historia es el mejor predictor del desbalance futuro.
frec_censura	Proporción de semanas pasadas en que esa estación y hora mostró huella de censura	P2	Señala estaciones que se vacían o llenan de forma recurrente aunque el flujo neto no lo muestre.
pred_salidas_p1	Pronóstico de P1 para la misma estación y hora	P2	Conecta la demanda esperada con el riesgo; se usa la predicción, no el valor real, para no filtrar el futuro.
temperatura, lluvia_mm	Clima horario pronosticado (en entrenamiento, el observado)	P1, P2	La lluvia reduce los viajes de forma inmediata, sobre todo en temporada de lluvias.
evento_masivo	Indicador de partidos y eventos en el área	P1, P2	Explica picos anómalos (Mundial 2026) que de otro modo se tratarían como ruido.
perfil_salidas_h, perfil_llegadas_h (96), razon_lleg_sal, dur_mediana, pct_circulares	Perfil normalizado por estación	P3	Distinguen estaciones residenciales (salidas por la mañana), laborales (llegadas por la mañana), mixtas y recreativas (fin de semana, viajes circulares).
cluster_p3	Cluster asignado a la estación	P1, P2	Resume el tipo de estación en una sola variable y ayuda a las estaciones con poca historia.

3. MODELOS Y MÉTRICAS

Las métricas siguen la guía de evaluación de modelos de scikit-learn (scikit-learn.org/stable/modules/model_evaluation.html). En MLflow cada métrica lleva el prefijo del conjunto en que se calcula (val_ o test_).

Pregunta	Baseline	Modelos candidatos	Métricas	Por qué son coherentes con la tarea y la decisión
P1 Regresión de conteos	Estacional ingenuo: misma estación y hora de la semana anterior (lag_168h).	Regresión de Poisson (PoissonRegressor); LightGBM con objetivo Poisson; opcional HistGradientBoostingRegressor(loss="p oi sson").	mean_absolute_error, root_mean_squared_error, mean_poisson_deviance, d2_tweedie_score (power=1) y WAPE = suma de errores absolutos / suma de viajes reales.	La variable es un conteo no negativo con muchos ceros: la desviancia de Poisson (desviancia Tweedie con power = 1 en la guía) evalúa el modelo bajo ese mismo supuesto. MAE y WAPE están en viajes, la unidad con la que el operador asigna bicicletas. MAPE se descarta porque la guía advierte que da valores arbitrariamente grandes cuando el valor real es cero. RMSE penaliza los errores grandes en horas pico, que son los que más afectan la flota.
P2 Clasificación multiclase desbalanceada	Regla del tercer cuartil: alertar cuando las salidas (o llegadas) de la hora superan el Q3 propio de la estación.	Regresión logística multinomial con class_weight="balanced"; LightGBM con pesos de clase; calibración con CalibratedClassifierCV.	Costo esperado con un scorer propio (make_scorer); average_precision_score por clase; precision_recall_fscore_support y f1 macro; brier_score_loss y curva de calibración.	La decisión es enviar o no un camión, con costos distintos para cada error: el costo esperado mide exactamente esa decisión. Con clases raras, accuracy y ROC-AUC dan una imagen optimista; average precision (PR-AUC) se concentra en la clase minoritaria. El umbral 1/(1+c) solo es válido con probabilidades calibradas, por eso se mide el Brier. TunedThresholdClassifierCV permite ajustar el umbral con el mismo scorer de costo.
P3 Clustering	Agrupación por municipio (prefijo GDL, ZPN, TLQ de la nomenclatura).	K-Means sobre componentes principales; AgglomerativeClustering (Ward); GaussianMixture.	silhouette_score, davies_bouldin_score, calinski_harabasz_score; estabilidad con Jaccard bootstrap por cluster y adjusted_rand_score entre periodos.	Sin etiquetas verdaderas solo se pueden usar índices internos (cohesión y separación) y de estabilidad. El baseline por municipio responde si los perfiles de uso aportan algo que la geografía administrativa no explica. La estabilidad importa porque planeación usará los grupos para decidir dónde abrir estaciones durante años.

Los criterios de aprobación de cada pregunta y su justificación están en la hoja "Criterios de aprobación y su justificación".

4. ARQUITECTURA DEL SISTEMA

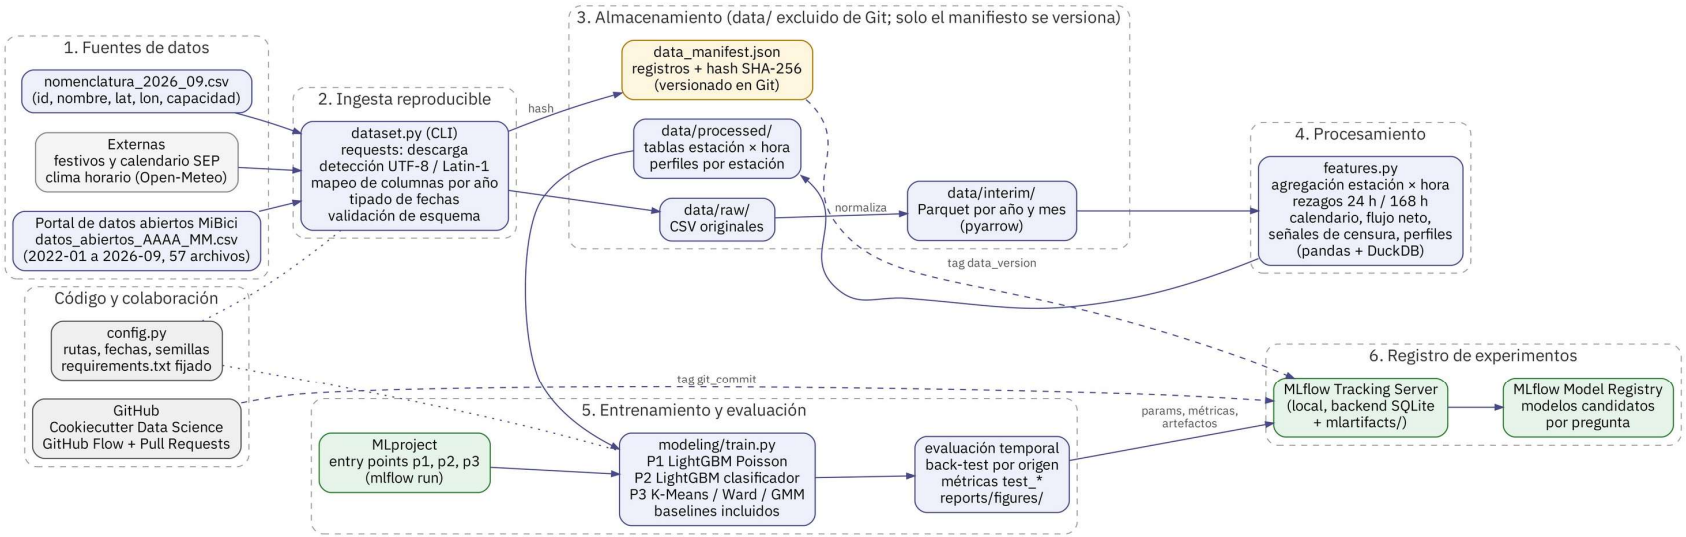


Diagrama realizado con Claude (LLM de Anthropic)

Las líneas punteadas indican configuración compartida; las discontinuas, metadatos que se adjuntan a cada run (versión de los datos y commit). El diagrama y el ML Canvas se guardan también en references/ del repositorio.

Herramientas por componente y justificación

Componente	Herramienta	Justificación
Estructura del proyecto	Cookiecutter Data Science (ccds) con include_code_scaffold	Separa datos, notebooks, código, modelos y reportes con una convención conocida. Responde a la deuda de "pipeline jungles" y "glue code" que describen Sculley et al. (2015), y a la modularidad del código que plantea Wilson (2022, cap. 9).
Fuentes e ingesta	Python 3.12, requests; dataset.py ejecutable desde la terminal	La ingesta debe ser reproducible y sin pasos manuales: un comando descarga, normaliza y guarda. El mapeo de columnas por año vive en código versionado y no en pasos manuales de un notebook.
Almacenamiento	Parquet con pyarrow en data/interim y data/processed	Formato columnar comprimido y tipado: carga solo las columnas necesarias y conserva los tipos de fecha, algo que el CSV no hace. Necesario para manejar decenas de millones de viajes en una laptop.
Versión de los datos	Manifiesto JSON (registros y hash SHA-256 por archivo, con hashlib) versionado en Git	Es la opción sencilla que propone la actividad y basta porque los datos de origen son públicos y se pueden volver a descargar. El hash del manifiesto se registra como tag data_version en cada run de MLflow. Huyen (2022, cap. 6) subraya que sin versionar los datos un experimento no se puede reproducir.
Procesamiento	pandas y DuckDB en features.py	DuckDB agrega directamente sobre los archivos Parquet con SQL, sin cargar todo en memoria; pandas se usa sobre las tablas ya agregadas. Las funciones tienen docstring y solo usan información disponible antes de la predicción.
Entrenamiento	scikit-learn y LightGBM; MLflow Projects (MLproject con entry points p1, p2 y p3)	scikit-learn da baselines, validación temporal y métricas estándar; LightGBM soporta objetivo Poisson y maneja bien variables mixtas. MLflow Projects empaqueta entorno, punto de entrada y parámetros para que cualquiera ejecute el experimento con un solo comando (mlflow run), como plantea el material de la semana sobre refactorización y Projects.
Registro de experimentos	MLflow Tracking (servidor local, backend SQLite, mlartifacts/) y Model Registry	Un experimento por proyecto y runs con nombre descriptivo; se registran rango de fechas, versión de datos, semilla, hiperparámetros, métricas test_* y el commit de Git. Wilson (2022, cap. 6) y Lauchande (2021, cap. 5) muestran que el seguimiento sistemático de experimentos y el registro de modelos permiten comparar candidatos y promover uno con trazabilidad.
Código y colaboración	Git y GitHub con GitHub Flow, Conventional Commits y Pull Requests	Rama principal protegida y revisión entre integrantes antes de integrar; cada run queda ligado a un commit revisado.
Configuración y entorno	config.py; requirements.txt con versiones fijadas	Rutas, fechas y semillas en un solo lugar, contra la "configuration debt" de Sculley et al. (2015); versiones fijadas para que el mismo código dé el mismo resultado en otra máquina.

Referencias: Sculley, D. et al. (2015). Hidden technical debt in machine learning systems. NeurIPS. Huyen, C. (2022). Designing Machine Learning Systems, cap. 6. O'Reilly. Wilson, B. (2022). Machine Learning Engineering in Action, caps. 6 y 9. Manning. Lauchande, N. (2021). Machine Learning Engineering with MLflow, cap. 5. Packt. de Montjoye, Y.-A., Hidalgo, C. A., Verleysen, M. y Blondel, V. D. (2013). Unique in the crowd: The privacy bounds of human mobility. Scientific Reports, 3, 1376.

5. EXPERIMENTO BASE EN MLFLOW: EJECUCIÓN Y RESULTADOS

5.1 Cómo se ejecuta y qué registra cada run

El experimento base corre desde el módulo del repositorio (no desde el notebook). Desde un clon limpio, con el servidor de MLflow en el puerto 5001 y el archivo .env copiado de .env.example, los comandos son:

```
python -m mibici.dataset            # descarga 2022-01 a 2026-09, normaliza, guarda Parquet y escribe data_manifest.json
python -m mibici.features           # panel estación × hora (14,377,703 filas) y perfiles de 371 estaciones
python -m mibici.modeling.train all # 4 runs en el experimento mibici-equipo24
# equivalente con MLflow Projects:  mlflow run . -e p1 --env-manager local --experiment-name mibici-equipo24
```

Todos los runs se agrupan en el experimento **mibici-equipo24** y comparten las etiquetas team = equipo24, question (P1, P2 o P3), stage = experimento_base, data_version = 9710a8a4ce41, git_commit = 9df1724 y git_dirty = false. Los parámetros de reproducción comunes son start_month = 2022-01, end_month = 2026-09, los límites de la partición temporal (train_end, val_start, val_end, test_start, test_end), data_version y seed = 42. Las métricas llevan el prefijo del conjunto en que se calculan (train_, val_, test_). No se registra ningún dato a nivel de viaje ni de usuario.

Run (nombre descriptivo)	Pregunta	Baseline	Parámetros propios	Métricas registradas	Artefactos
p1-baseline-estacional-lag168h	P1	Misma estación y hora de la semana anterior	model = seasonal_naive_lag168h, horizon_h = 24, lag_hours = 168	val_/test_ mae, rmse, wape, poisson_deviance, wape_poisson_floor, wape_station_day	figures/p1_wape_vs_piso_poisson.png; tables/p1_wape_por_nivel_de_demanda.csv
p2-baseline-regla-q3	P2	Alerta si salidas o llegadas de hace 168 h superan el Q3 propio de la estación	model = rule_station_q3, baseline_quantile = 0.75, label_netflow_threshold = 0.5, cost_fn_over_fp = 3.0	train_prevalence_*; val_/test_ f1_macro, expected_cost_per_1000, alert_rate, precision/recall/f1 por clase	figures/p2_matriz_confusion_test.png
p3-baseline-municipio	P3	Agrupación por municipio (prefijo GDL, ZPN, TLQ)	model = municipio, n_features = 99, pca_components = 47, n_stations = 371	train_silhouette, train_davies_bouldin, train_calinski_harabasz, train_n_clusters	mapa y perfiles por grupo; tabla de asignación
p3-kmeans-k5	P3	Primer candidato: K-Means sobre PCA (90% de varianza)	model = kmeans, k = 5, n_init = 20, pca_variance = 0.9	las anteriores + train_jaccard_bootstrap_mean, train_ari_vs_municipio	mapa y perfiles por grupo; tabla de asignación

5.2 Resultados P1: demanda por estación y hora

Métrica	Validación (jul-dic 2025)	Prueba (ene-sep 2026)	Lectura
MAE (viajes por estación-hora)	0.959	0.930	Error medio de casi 1 viaje en celdas con muy pocos viajes
RMSE	1.845	1.882	Los errores grandes se concentran en horas pico
WAPE estación-hora	71.2%	75.5%	Nivel al que se toma la decisión del día siguiente
WAPE mínimo posible (piso Poisson)	50.3%	50.6%	Error irreducible aun conociendo la media exacta
WAPE estación-día	20.8%	25.7%	Al agregar a día el error baja a una cuarta parte
Desviancia de Poisson media	2.503	2.716	Métrica coherente con un objetivo de conteo

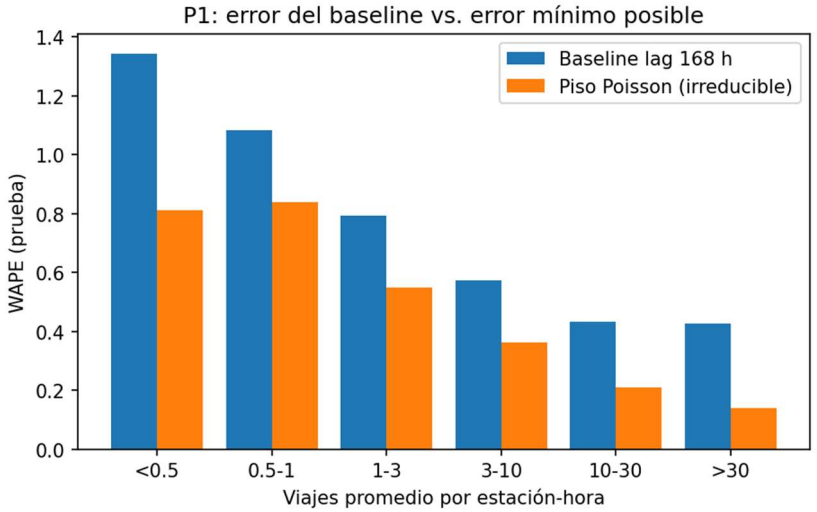


Figura 5.1. WAPE del baseline frente al piso Poisson por nivel de demanda (prueba).

Lectura. En prueba el baseline estacional tiene un WAPE de 75.5% a nivel estación-hora, contra un mínimo posible de 50.6%. La brecha reducible es de 25.0 puntos. Con el criterio de aprobación de la propuesta (cerrar al menos 50% de esa brecha), un modelo candidato tendrá que bajar el WAPE de prueba a **63.0% o menos**.

Por nivel de demanda. La brecha es de 21 a 29 puntos en todos los niveles y llega a 53 puntos en las celdas con menos de 0.5 viajes promedio, donde repetir el valor de la semana anterior es casi siempre un error. Ahí hay más margen para un modelo que use promedios móviles y atributos de la estación.

Prueba más difícil que validación. El WAPE sube de 71.2% a 75.5% entre validación y prueba. Coincide con la expansión de la red (de 371 a 469 estaciones en el panel entre jun y sep de 2026) y con los partidos del Mundial; es una hipótesis que se evaluará reportando la prueba también sin esos días, como indica la sección 1.6.

5.3 Resultados P2: riesgo de vaciado o saturación

Métrica (prueba, ene-sep 2026)	normal	vaciado	saturación	Global
Prevalencia de la etiqueta en entrenamiento	99.19%	0.45%	0.36%	riesgo: 0.81%
Precisión	0.995	0.015	0.014	—
Recall (sensibilidad)	0.768	0.343	0.529	—
F1	0.867	0.028	0.027	F1 macro = 0.307
Tasa de alertas				23.4%
Costo esperado por 1,000 estación-horas (c = 3)				242.0

Lectura. La regla Q3 alerta en 23.4% de las estación-horas, pero la etiqueta de riesgo solo ocurre en 0.83% de ellas en el periodo de prueba. Por eso detecta entre 34% y 53% de los riesgos con una precisión de apenas 1.4%: de cada 100 visitas de camión que dispararía, solo una o dos llegarían a una estación en riesgo. La matriz de confusión del artefacto (sección 6, Figura 6.3) muestra que 23% de las horas normales se marcan como riesgo.

Hallazgo para la siguiente entrega. Con el costo configurado (un riesgo no avisado vale 3 visitas), **no alertar nunca costaría 24.8** por cada 1,000 estación-horas en prueba, diez veces menos que la regla Q3 (242.0). El baseline confirma lo que anticipa la sección de criterios: la regla Q3 es una referencia razonable de comportamiento, no un modelo útil. Para la siguiente entrega el equipo (1) agregará "no alertar" como segunda referencia de costo, (2) calibrará el umbral 0.5 de flujo neto y el criterio de huella de censura con la distribución de entrenamiento, porque con los valores actuales la clase de riesgo es muy rara, y (3) estimará c a partir de los viajes perdidos en lugar de fijarlo en 3.

5.4 Resultados P3: tipologías de estaciones

Métrica (perfiles de entrenamiento, 371 estaciones)	Baseline por municipio	K-Means k = 5	Criterio de la propuesta	¿Cumple K-Means?
Silueta (mayor es mejor)	0.025	0.086	> 0.25	No
Davies-Bouldin (menor es mejor)	5.44	2.47	Comparativo	Mejora 55%
Calinski-Harabasz (mayor es mejor)	3.0	33.6	Comparativo	11 veces mayor
Jaccard bootstrap promedio	—	0.64	≥ 0.75 por grupo	No (estabilidad media)
ARI contra municipio	—	-0.002	Diagnóstico	Independiente de la geografía

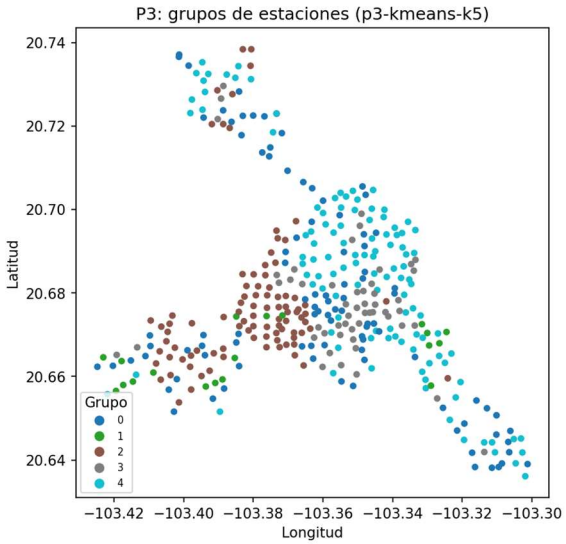


Figura 5.2. Grupos de K-Means en el mapa.

Lectura. K-Means supera al baseline por municipio en los tres índices internos y su ARI contra el municipio es prácticamente cero: los perfiles de uso contienen información que la geografía administrativa no explica, que es justo la pregunta que responde el baseline. Aun así, ningún modelo cumple todavía los criterios de aprobación (silueta > 0.25 y Jaccard ≥ 0.75), así que estos grupos son un punto de partida y no la tipología final.

Los cinco grupos son interpretables (perfiles en la Figura 5.3):

- **Grupo 2 (92 estaciones), destino laboral:** llegadas con pico a las 8-9 h y salidas a las 17 h; se concentra en el centro-poniente.
- **Grupo 4 (112), origen residencial:** salidas de 6 a 9 h y llegadas por la tarde y noche; norte y oriente de la red.
- **Grupo 3 (52), actividad de mediodía:** salidas y llegadas con pico de 11 a 14 h, en el centro.
- **Grupo 0 (96), mixto** y **Grupo 1 (19), periférico** de uso vespertino, en los bordes de la red.

Siguiente paso: comparar Ward y GMM, elegir k entre 3 y 10 con silueta y estabilidad, y reducir la dimensión de los 99 rasgos (hoy 47 componentes) para mejorar la separación.

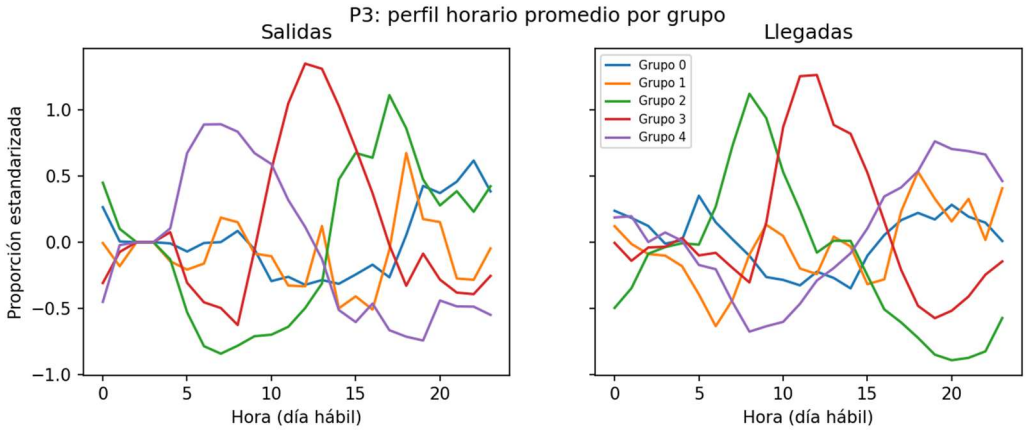


Figura 5.3. Perfil horario promedio estandarizado por grupo en día hábil (salidas y llegadas).

5.5 Reproducibilidad comprobada

Para validar la lista de verificación de la actividad, el pipeline se ejecutó desde un clon limpio del repositorio (commit 9df1724, rama main), siguiendo solo el README:

- **Ingesta idéntica:** la descarga y normalización produjo data_version = 9710a8a4ce41 y 20,305,321 viajes limpios; el data_manifest.json generado no tiene diferencias con el versionado en Git y python -m mibici.dataset verify confirma los 57 hashes.
- **Runs ligados al código:** los cuatro runs registran git_commit y git_dirty = false, y se reconstruyen en menos de 2 minutos una vez creado el panel (la ingesta completa toma unos 7 minutos).
- **Dos detalles que conviene corregir en el repositorio:** (1) python -m mibici.dataset --help falla porque typer 0.15.2 no es compatible con click 8.2 o superior, que requirements.txt no fija; basta con agregar click<8.2. (2) Detrás de un proxy con inspección TLS, requests no confía en el certificado del portal; se resolvió con el paquete pip-system-certs sin cambiar el código. Ninguno afecta los resultados.

6. EVIDENCIA EN LA INTERFAZ DE MLFLOW

Capturas del servidor de MLflow 2.22 (backend SQLite, artefactos servidos por el propio servidor) con el experimento mibici-equipo24, tal como pide el paso 7 de la actividad.

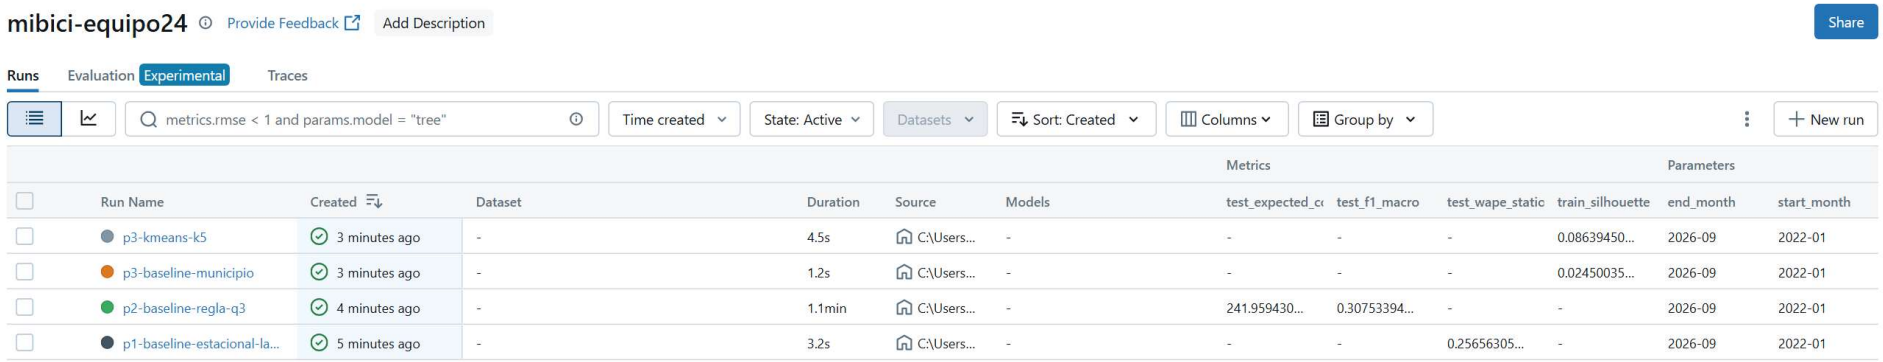


Figura 6.1. Lista de runs del experimento mibici-equipo24: un run por pregunta y nombres descriptivos, con columnas de métricas (test_expected_cost_per_1000, test_f1_macro, test_wape_station_day, train_silhouette) y parámetros (start_month, end_month).

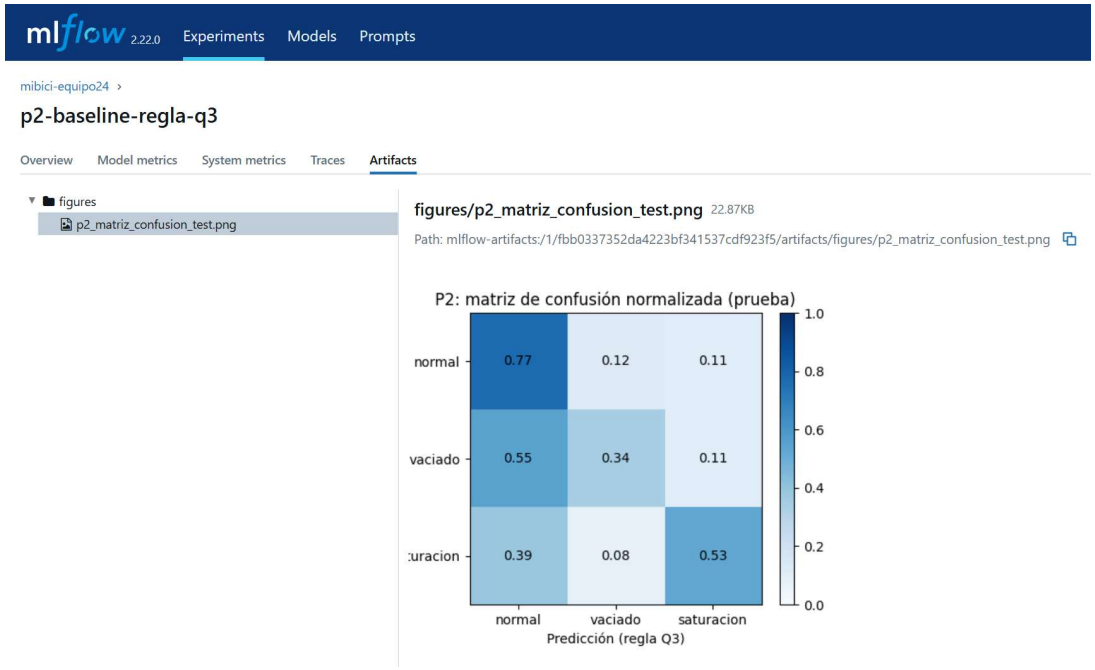


Figura 6.3. Artefacto registrado: matriz de confusión normalizada del run p2-baseline-regla-q3 (prueba).

6. EVIDENCIA EN LA INTERFAZ DE MLFLOW (CONTINUACIÓN)

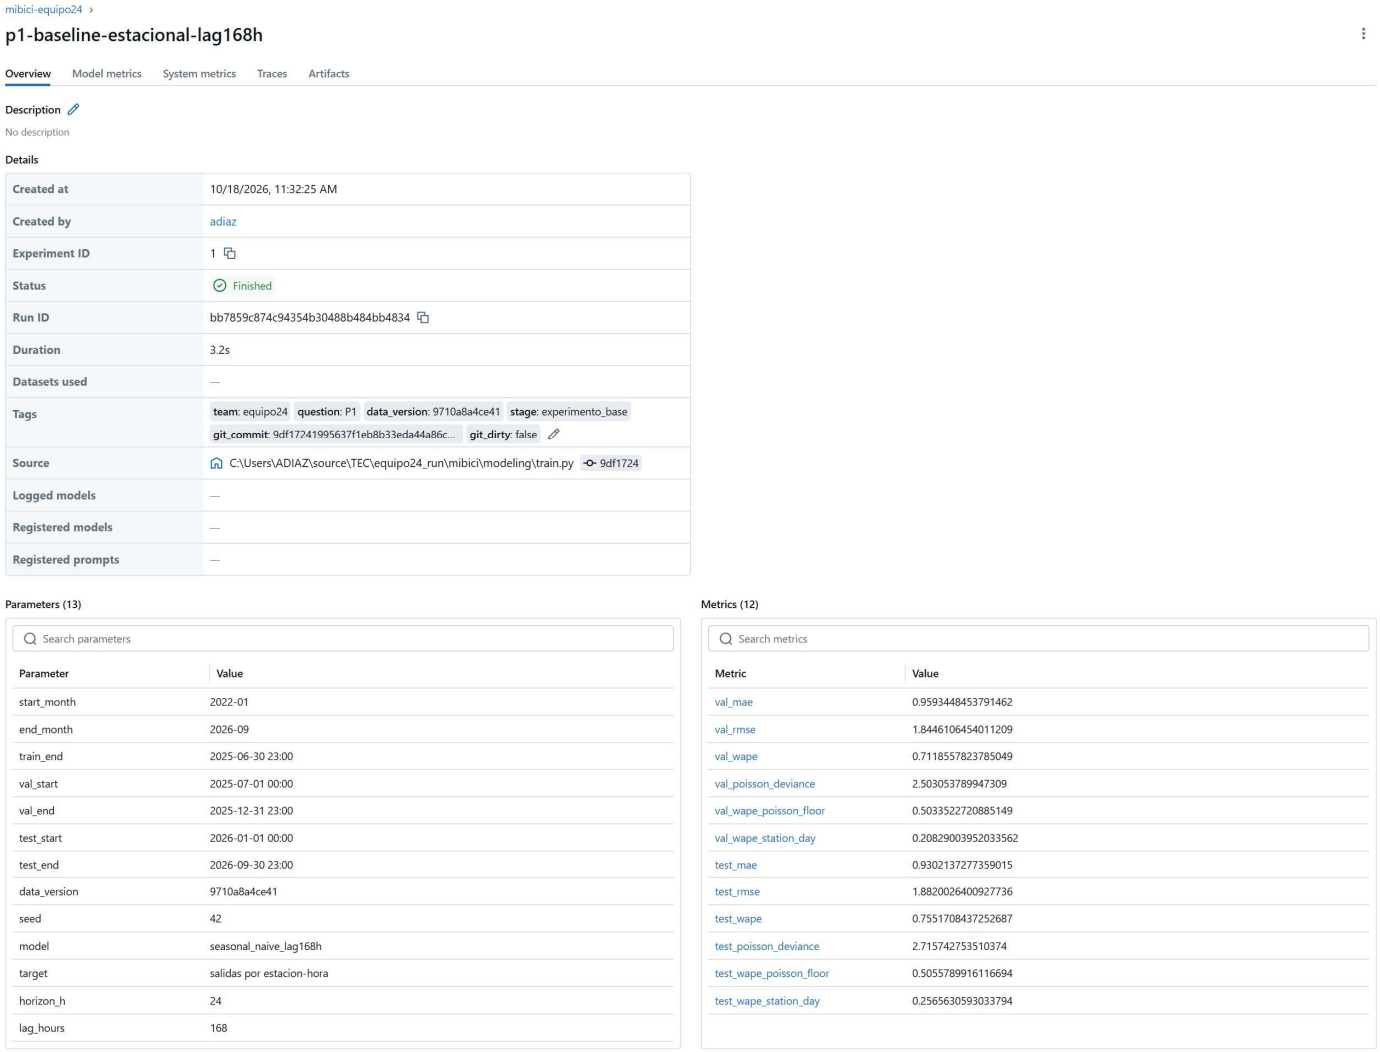
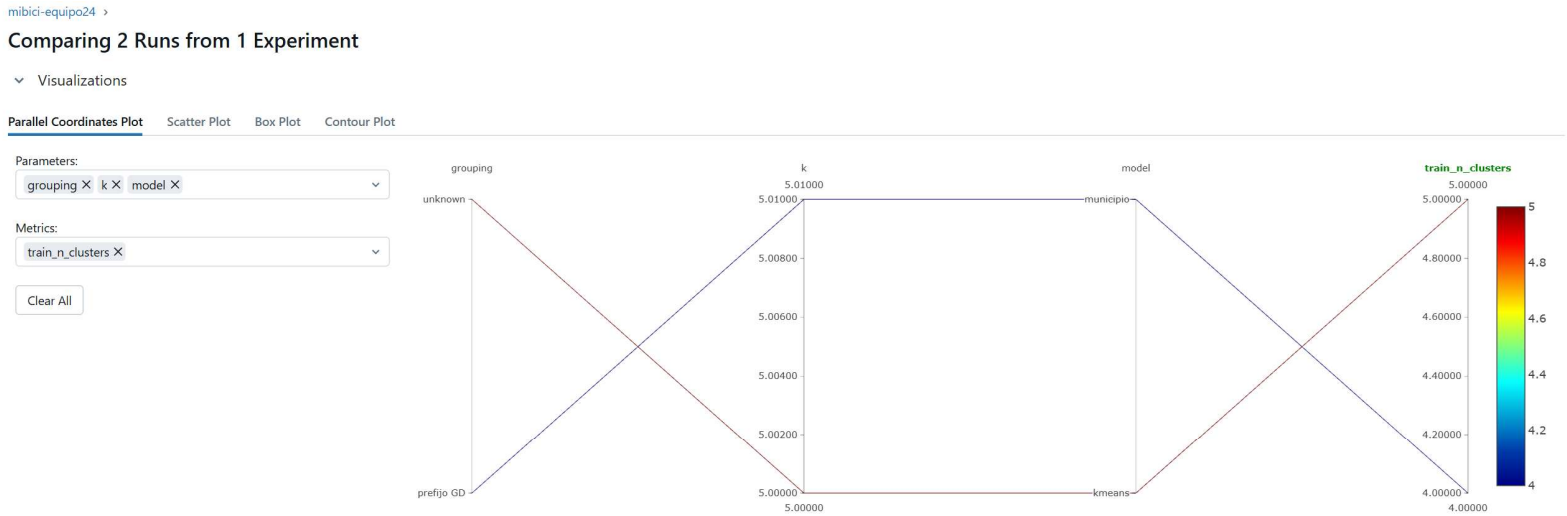


Figura 6.2. Detalle del run p1-baseline-estacional-lag168h: etiquetas (team, question, data_version, git_commit, git_dirty, stage), 13 parámetros de reproducción y 12 métricas con prefijo val_ y test_.

6. EVIDENCIA EN LA INTERFAZ DE MLFLOW (CONTINUACIÓN)



Run details

Run ID:	d89562338ca943b8bbb13e4bedced369	36253be510394c15a6a5659c733d63c2
Run Name:	p3-baseline-municipio	p3-kmeans-k5
Start Time:	10/18/2026, 11:33:36 AM	10/18/2026, 11:33:37 AM
End Time:	10/18/2026, 11:33:37 AM	10/18/2026, 11:33:42 AM
Duration:	1.2s	4.5s

Parameters

Show diff only

grouping	prefijo GDL/ZPN/TLQ de la nomenclatura	
k		5
model	municipio	kmeans
n_init		20

Metrics

Show diff only

train_ari_vs_municipio		-0.001
train_calinski_harabasz	2.99	33.62
train_davies_bouldin	5.435	2.466
train_jaccard_bootstrap_mean		0.639
train_n_clusters	4	5
train_silhouette	0.025	0.086

Figura 6.4. Comparación de dos runs (p3-baseline-municipio contra p3-kmeans-k5): parámetros y métricas que difieren entre ambos.

7. REPOSITORIO Y FLUJO DE TRABAJO CON GIT/GITHUB

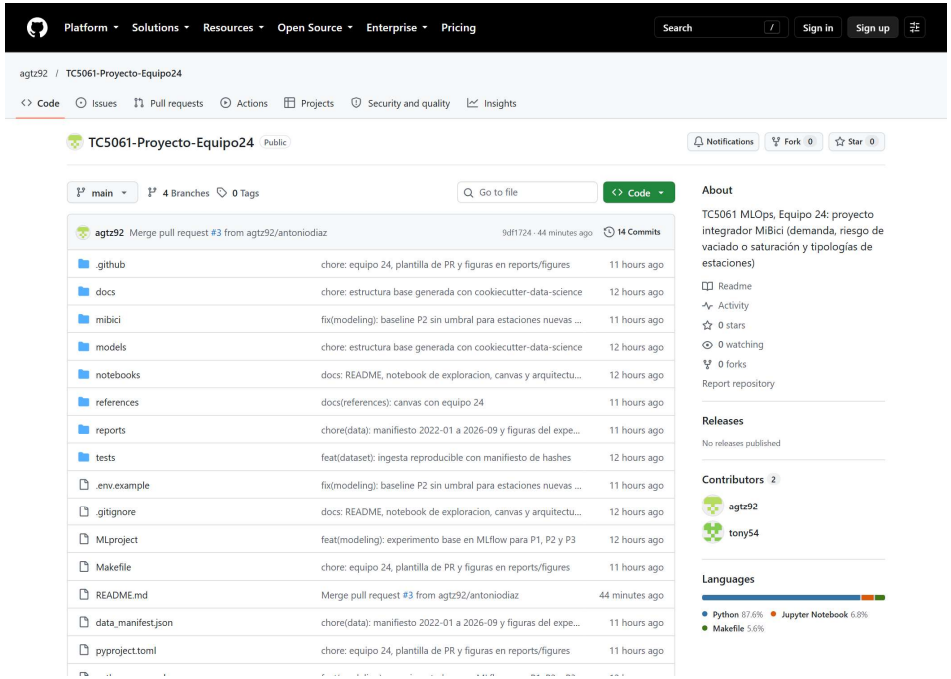


Figura 7.1. Estructura del repositorio en GitHub (rama main).

Repositorio: https://github.com/agtz92/TC5061-Proyecto-Equipo24

Estructura. Generada con Cookiecutter Data Science (ccds con include_code_scaffold = Yes) como primer commit. Se respeta la separación de carpetas de la plantilla:

- **mibici/**: módulo del proyecto con config.py (rutas, fechas, partición, semillas, umbrales y MLflow), dataset.py (ingesta y manifiesto), features.py (panel, rezagos, etiquetas de P2, perfiles de P3) y modeling/train.py (experimento base).
- **notebooks/**: solo exploración, 1.0-jagg-exploracion-viajes.ipynb.
- **references/**: ML Canvas (docx y pdf), propuesta y diagrama de arquitectura (.dot y .png).
- **reports/figures/**: figuras del experimento base. **models/** y **data/** quedan fuera de Git.
- **data_manifest.json**: versión de los datos (hash SHA-256 y registros por archivo), sí versionado.
- **requirements.txt** con versiones fijas, **python_env.yaml** y **MLproject** para mlflow run.

.gitignore ampliado: excluye data/, mlruns/, mlartifacts/, *.db, models/ y .env.

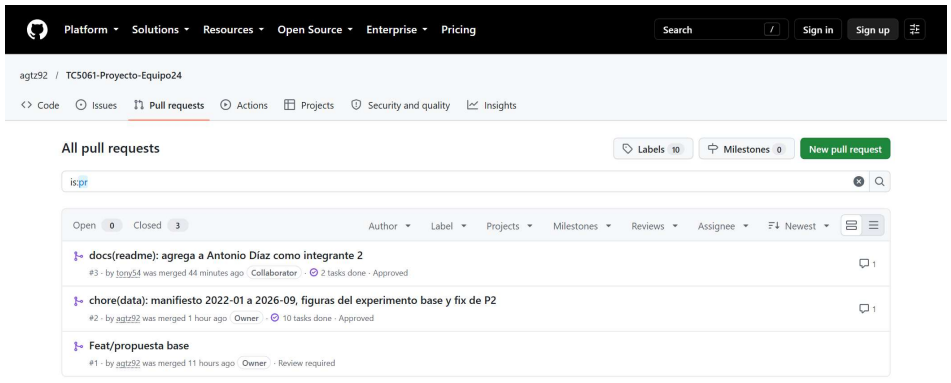


Figura 7.2. Pull Requests del repositorio, todos revisados antes de integrarse.

Flujo de trabajo (documentado en el README).

- **GitHub Flow:** main está protegida; nadie hace push directo y todo cambio entra por Pull Request con al menos una aprobación.
- **Ramas** tipo/descripcion-corta (feat, fix, docs, exp, chore) y **commits** con Conventional Commits en español, p. ej. fix(modeling): baseline P2 sin umbral para estaciones nuevas.
- **Plantilla de PR** en .github/: qué cambia, pregunta que atiende, cómo se probó y lista de revisión (sin datos ni .env).
- **Revisión entre integrantes:** el autor no aprueba su propio PR; el PR #2 se aprobó con comentario de otro integrante.

Cada integrante abre al menos un Pull Request y revisa uno de otra persona antes de la entrega.

Buenas prácticas obligatorias y dónde se cumplen

Ámbito	Práctica	Cómo se cumple	Evidencia
MLflow	Un experimento por proyecto y runs con nombre descriptivo	mibici-equipo24; run_name explícito en cada run	Figura 6.1
MLflow	Registrar lo necesario para reproducir	Rango de fechas, partición, data_version, seed, modelo e hiperparámetros	Figura 6.2
MLflow	Ligar el run al código y a la pregunta	Etiquetas git_commit, git_dirty, question y team	Figura 6.2
MLflow	Métricas con el conjunto en el nombre	val_mae, test_wape, train_silhouette, etc.	Figuras 6.2 y 6.4
MLflow	Sin credenciales ni datos personales	Columnas personales eliminadas en la ingesta; solo agregados por estación-hora	dataset.py; sección 1.5
Estructura	Notebooks solo para exploración	1.0-jagg-exploracion-viajes.ipynb; la lógica vive en mibici/	Figura 7.1
Estructura	Configuración en un solo lugar	Rutas, fechas, semillas, umbrales y URI de MLflow en config.py	mibici/config.py
Estructura	Dependencias fijas y entorno reproducible	requirements.txt con versiones exactas; reproducido desde un clon limpio	Sección 5.5
Datos y Git	Sin datos, modelos, MLflow ni credenciales en Git	.gitignore ampliado; el historial no contiene data/ ni mlruns/	.gitignore
Datos y Git	Todo cambio entra por Pull Request revisado	main protegida, PR con aprobación obligatoria	Figura 7.2

8. REFERENCIAS

Agencia Metropolitana de Servicios de Infraestructura para la Movilidad. (2026). *Datos abiertos de MiBici* [Conjunto de datos]. MiBici. https://www.mibici.net/es/datos-abiertos/

Conventional Commits. (s.f.). *Conventional Commits 1.0.0*. https://www.conventionalcommits.org/es/v1.0.0/

de Montjoye, Y.-A., Hidalgo, C. A., Verleysen, M., & Blondel, V. D. (2013). Unique in the crowd: The privacy bounds of human mobility. *Scientific Reports, 3*, Artículo 1376. https://doi.org/10.1038/srep01376

Diebold, F. X., & Mariano, R. S. (1995). Comparing predictive accuracy. *Journal of Business & Economic Statistics, 13*(3), 253-263. https://doi.org/10.1080/07350015.1995.10524599

Dorard, L. (s.f.). *Machine Learning Canvas* (Versión 1.2) [Plantilla]. OwnML. https://www.ownml.co/machine-learning-canvas

DrivenData. (s.f.). *Cookiecutter Data Science* [Software]. https://cookiecutter-data-science.drivendata.org/

GitHub. (s.f.). *GitHub flow*. GitHub Docs. https://docs.github.com/es/get-started/using-github/github-flow

Hennig, C. (2007). Cluster-wise assessment of cluster stability. *Computational Statistics & Data Analysis, 52*(1), 258-271. https://doi.org/10.1016/j.csda.2006.11.025

Huyen, C. (2022). *Designing machine learning systems*. O'Reilly Media.

Kaufman, L., & Rousseeuw, P. J. (1990). *Finding groups in data: An introduction to cluster analysis*. Wiley. https://doi.org/10.1002/9780470316801

Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q., & Liu, T.-Y. (2017). LightGBM: A highly efficient gradient boosting decision tree. En *Advances in Neural Information Processing Systems 30* (pp. 3146-3154). Curran Associates.

Lauchande, N. (2021). *Machine learning engineering with MLflow*. Packt Publishing.

MLflow. (s.f.). *MLflow Tracking* [Documentación]. https://mlflow.org/docs/latest/tracking.html

Open-Meteo. (s.f.). *Historical weather API* [Documentación]. https://open-meteo.com/en/docs/historical-weather-api

pandas development team. (s.f.). *pandas.DataFrame.to_parquet* [Documentación]. https://pandas.pydata.org/docs/reference/api/pandas.DataFrame.to_parquet.html

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research, 12*, 2825-2830.

scikit-learn developers. (s.f.). *Metrics and scoring: Quantifying the quality of predictions* [Documentación]. https://scikit-learn.org/stable/modules/model_evaluation.html

Sculley, D., Holt, G., Golovin, D., Davydov, E., Phillips, T., Ebner, D., Chaudhary, V., Young, M., Crespo, J.-F., & Dennison, D. (2015). Hidden technical debt in machine learning systems. En *Advances in Neural Information Processing Systems 28* (pp. 2503-2511). Curran Associates.

Wilson, B. (2022). *Machine learning engineering in action*. Manning Publications.

ANEXO A. ARCHIVOS DESCARGADOS POR MES

Conteo realizado el 17 de octubre de 2026 sobre los archivos publicados en el portal. Filas = viajes (sin encabezado). Estaciones = identificadores distintos en origen o destino ese mes.

Mes	Viajes	Estac.	Codif.	Archivo
2022-01	289,864	300	Latin-1	datos_abiertos_2022_01.csv
2022-02	313,752	300	Latin-1	datos_abiertos_2022_02.csv
2022-03	377,505	300	Latin-1	datos_abiertos_2022_03.csv
2022-04	330,094	300	Latin-1	datos_abiertos_2022_04.csv
2022-05	373,701	300	Latin-1	datos_abiertos_2022_05.csv
2022-06	351,595	300	Latin-1	datos_abiertos_2022_06.csv
2022-07	334,356	300	Latin-1	datos_abiertos_2022_07.csv
2022-08	363,161	300	Latin-1	datos_abiertos_2022_08.csv
2022-09	375,014	300	Latin-1	datos_abiertos_2022_09.csv
2022-10	390,156	300	Latin-1	datos_abiertos_2022_10.csv
2022-11	381,192	300	Latin-1	datos_abiertos_2022_11.csv
2022-12	322,552	300	UTF-8	datos_abiertos_2022_12.csv
2023-01	366,018	300	Latin-1	datos_abiertos_2023_01.csv
2023-02	355,291	300	Latin-1	datos_abiertos_2023_02.csv
2023-03	402,460	300	Latin-1	datos_abiertos_2023_03.csv
2023-04	333,211	300	UTF-8	datos_abiertos_2023_04.csv
2023-05	364,184	300	UTF-8	datos_abiertos_2023_05.csv
2023-06	339,628	300	Latin-1	datos_abiertos_2023_06.csv
2023-07	331,787	300	Latin-1	datos_abiertos_2023_07.csv
2023-08	354,810	300	Latin-1	datos_abiertos_2023_08.csv
2023-09	363,859	300	Latin-1	datos_abiertos_2023_09.csv
2023-10	383,239	320	Latin-1	datos_abiertos_2023_10.csv
2023-11	384,464	357	Latin-1 †	datos_abiertos_2023_11.csv
2023-12	314,164	359	Latin-1	datos_abiertos_2023_12.csv
2024-01	391,591	360	Latin-1	datos_abiertos_2024_01.csv
2024-02	383,732	360	Latin-1 *	datos_abiertos_2024_02.csv
2024-03	390,513	360	Latin-1	datos_abiertos_2024_03.csv
2024-04	405,308	360	Latin-1	datos_abiertos_2024_04.csv
2024-05	410,806	360	Latin-1 *	datos_abiertos_2024_05.csv
2024-06	365,000	362	Latin-1	datos_abiertos_2024_06.csv
2024-07	364,177	360	UTF-8	datos_abiertos_2024_07.csv
2024-08	394,894	360	Latin-1	datos_abiertos_2024_08.csv
2024-09	390,072	360	Latin-1 †	datos_abiertos_2024_09.csv
2024-10	418,690	360	Latin-1 †	datos_abiertos_2024_10.csv
2024-11	391,089	360	Latin-1	datos_abiertos_2024_11.csv
2024-12	340,049	368	Latin-1	datos_abiertos_2024_12.csv
2025-01	380,184	368	Latin-1	datos_abiertos_2025_01.csv
2025-02	372,529	367	Latin-1	datos_abiertos_2025_02.csv
2025-03	405,110	367	UTF-8	datos_abiertos_2025_03.csv
2025-04	366,193	367	UTF-8	datos_abiertos_2025_04.csv
2025-05	395,891	367	UTF-8	datos_abiertos_2025_05.csv
2025-06	356,611	368	UTF-8	datos_abiertos_2025_06.csv
2025-07	368,186	367	Latin-1	datos_abiertos_2025_07.csv
2025-08	374,727	367	UTF-8	datos_abiertos_2025_08.csv
2025-09	376,789	367	UTF-8	datos_abiertos_2025_09.csv
2025-10	420,064	368	UTF-8	datos_abiertos_2025_10.csv
2025-11	380,328	367	UTF-8	datos_abiertos_2025_11.csv
2025-12	335,420	368	UTF-8	datos_abiertos_2025_12.csv
2026-01	357,180	368	Latin-1	datos_abiertos_2026_01.csv
2026-02	333,756	368	UTF-8	datos_abiertos_2026_02.csv
2026-03	376,243	369	UTF-8	datos_abiertos_2026_03.csv
2026-04	351,851	368	UTF-8	datos_abiertos_2026_04.csv
2026-05	315,895	371	UTF-8	datos_abiertos_2026_05.csv
2026-06	355,303	427	UTF-8	datos_abiertos_2026_06.csv
2026-07	388,257	453	UTF-8	datos_abiertos_2026_07.csv
2026-08	393,524	467	UTF-8	datos_abiertos_2026_08.csv
2026-09	490,056	468	UTF-8	datos_abiertos_2026_09.csv

* Encabezado de Año_de_nacimiento con caracteres corruptos. † Fechas en formato dd/mm/aaaa h:mm sin segundos (el resto usa aaaa-mm-dd hh:mm:ss). Ambos casos se resuelven en dataset.py con el mapeo de columnas por posición y un parser de fechas con los dos formatos.